Relatorio Tecnico de Explicabilidade

Previsao de Ksat (BHSE) - Modelo RF Tunado com Features Engenheiradas

1. Escopo e objetivo

Este relatorio consolida a analise de explicabilidade do modelo de previsao de log10(Ksat) para a BHSE, com foco em tres dimensoes:

1. Explicabilidade global: o que o modelo aprendeu como padrao geral.
2. Explicabilidade local: por que o modelo acertou ou errou em pontos especificos.
3. Diagnostico espacial de residuos: onde o modelo erra e se os erros tem estrutura geografica.

Modelo analisado:

Tipo: RandomForestRegressor
Feature set: engineered (17 variaveis)
Base de treino/validacao/teste: 70/15/15, seed 42
Referencia de robustez espacial adicional: Spatial-LOO com buffer de 50 m

Arquivos de entrada principais:

outputs_explainability/explainability_summary.json
outputs_explainability/holdout_metrics.json
outputs_explainability/spatial/sloo_summary.json
tabelas e figuras em outputs_explainability/global, local, spatial, diagnostics

2. Configuracao experimental

2.1 Dados e alvo

Fonte: Pontos_Ksat_Sanga_Ellert.xlsx
Amostras totais: 169
Alvo modelado: log_ksat = log10(Ksat)

2.2 Features usadas no modelo final

Base fisica e espacial:

x, y, sand, clay, bulk_density, macroporosity

Features derivadas:

sand_clay_ratio
macro_ds_ratio
clay_ds_product
macro_squared
sand_macro
log_ds
inv_clay
x_norm, y_norm
dist_center

spatial_interaction

2.3 Hiperparametros do modelo analisado

n_estimators = 582
max_depth = 21
min_samples_split = 3
min_samples_leaf = 5
max_features = 0.3898
max_samples = 0.8788

3. Desempenho de referencia para explicabilidade

3.1 Holdout (26 pontos de teste)

R2_log = 0.7602
RMSE_log = 0.2689
MAE_log = 0.2093
PBIAS_log = -2.35%
R2_orig = 0.5246
RMSE_orig = 1465.65 cm/dia
MAE_orig = 881.50 cm/dia

Interpretacao:

O modelo atinge bom desempenho no split holdout especifico, consistente com os melhores resultados vistos anteriormente.

3.2 Spatial-LOO com buffer 50 m (169 pontos)

R2_log = 0.5990
RMSE_log = 0.3521
MAE_log = 0.2701
R2_orig = 0.4050
RMSE_orig = 1486.82 cm/dia
MAE_orig = 968.18 cm/dia
Tamanho medio de treino por fold: 164.26 pontos
Fallback por falta de treino minimo: 0

Interpretacao:

A queda de performance no SLOO confirma que o problema tem componente espacial desafiador e que o holdout pode ser otimista.

4. Explicabilidade global

4.1 SHAP summary (global)

Figura:

outputs_explainability/global/shap_summary_bar.png
outputs_explainability/global/shap_summary_beeswarm.png

Top features por mean(|SHAP|):

1. sand_macro (0.1400)
2. macroporosity (0.1004)
3. macro_squared (0.0880)
4. macro_ds_ratio (0.0716)
5. sand (0.0178)
6. log_ds (0.0156)
7. bulk_density (0.0133)
8. x (0.0131)

Leitura:

O modelo esta centrado em variaveis de estrutura de poros/interacoes com macro, nao so em textura bruta.

A presenca de termos de interacao (sand_macro, macro_squared) como dominantes sugere forte nao-linearidade fisica aprendida.

4.2 Permutation importance com incerteza

Figura:

outputs_explainability/global/permutation_importance.png

Tabela:

outputs_explainability/global/permutation_importance.csv

Top features por queda media em R2:

1. sand_macro (0.1812 +/- 0.0700)
2. macroporosity (0.0710 +/- 0.0434)
3. macro_squared (0.0545 +/- 0.0378)
4. macro_ds_ratio (0.0416 +/- 0.0349)

Leitura:

SHAP e permutation convergem para o mesmo nucleo de importancia, reforcando robustez da interpretacao.

Algumas variaveis (log_ds, bulk_density, y) aparecem com importancia media ~0 ou negativa em permutation, sinalizando possivel redundancia no conjunto final.

4.3 PDP + ICE

Figura:

outputs_explainability/global/pdp_ice.png

Variaveis analisadas:

macroporosity, bulk_density, sand, clay

Leitura:

As curvas confirmam dependencias nao lineares e heterogeneidade local (ICE), principalmente para

variaveis estruturais.

O efeito medio nao e homogeneo entre amostras, o que justifica interacoes explicitas no feature engineering.

4.4 SHAP interactions

Figuras/tabelas:

outputs_explainability/global/shap_interaction_heatmap.png
outputs_explainability/global/shap_dependence_macro_vs_ds.png
outputs_explainability/global/shap_interaction_matrix.csv

Leitura:

Interacoes envolvendo macroporosity sao centrais, especialmente com bulk_density e termos derivados.
O modelo usa mecanismos combinados de textura + estrutura, nao relacoes univariadas simples.

5. Explicabilidade local

5.1 Pontos de referencia analisados

Tabela:

outputs_explainability/local/local_points_summary.csv

Pontos selecionados:

best_prediction: erro absoluto log 0.0079
worst_prediction: erro absoluto log 0.6518
highest_ksat: erro absoluto log 0.4218
lowest_ksat: erro absoluto log 0.3082

5.2 SHAP waterfall (caso a caso)

Figuras:

outputs_explainability/local/waterfall_best_prediction.png
outputs_explainability/local/waterfall_worst_prediction.png
outputs_explainability/local/waterfall_highest_ksat.png
outputs_explainability/local/waterfall_lowest_ksat.png

Leitura:

O pior erro ocorre em combinacao de variaveis onde efeitos de macro/interacao empurram fortemente a previsao para cima.

Em extremos de Ksat, o modelo tende a reduzir amplitude (subestimando picos altos e superestimando alguns baixos), comportamento comum em regressao com amostra pequena.

5.3 LIME local

Figuras:

outputs_explainability/local/lime_best_prediction.png
outputs_explainability/local/lime_worst_prediction.png

outputs_explainability/local/lime_highest_ksat.png
outputs_explainability/local/lime_lowest_ksat.png

Tabela:

outputs_explainability/local/lime_local_weights.csv

Leitura:

LIME confirma localmente o protagonismo de variaveis ligadas a macro e interacoes para a maioria dos pontos explicados.

5.4 Vizinhos influentes (proximidade no espaco de features)

Tabela:

outputs_explainability/local/local_nearest_neighbors.csv

Leitura:

Nos casos de maior erro, os vizinhos no espaco de features nem sempre tem alvo proximo, sugerindo overlap de regimes fisicos distintos.

5.5 Contrafactual simples (pior ponto)

Tabela:

outputs_explainability/local/counterfactual_worst_point.csv

Top ajustes que mais reduzem erro no pior ponto:

1. reduzir macroporosity
2. reduzir sand_macro
3. reduzir macro_squared
4. reduzir macro_ds_ratio

Leitura:

O erro extremo esta associado principalmente ao bloco de variaveis de macroestrutura, coerente com SHAP global/local.

6. Diagnostico espacial dos erros

6.1 Mapas de residuos

Figuras:

outputs_explainability/spatial/holdout_residual_maps.png
outputs_explainability/spatial/sloo_residual_maps.png

Leitura:

Ha padrao espacial de super/subestimacao em regioes especificas, mais claro no SLOO.
Isso sugere que parte da estrutura espacial do processo ainda nao foi totalmente capturada.

6.2 Variograma dos residuos

Arquivos:

outputs_explainability/spatial/residual_variogram_experimental.csv
outputs_explainability/spatial/residual_variogram_fit.json
outputs_explainability/spatial/residual_variogram_plot.png

Parametros ajustados (esferico):

nugget = 0.0997
sill = 0.0634
range = 1134.4 m
GDE = 61.1%

Interpretacao:

GDE intermediario (nao dominado por pepita pura) indica que os residuos nao sao totalmente aleatorios no espaco.
Ha sinal de dependencia espacial remanescente, implicando oportunidade para modelagem residual geoespacial adicional.

6.3 Correlacao |erro| x covariaveis

Tabela:

outputs_explainability/diagnostics/error_covariate_spearman.csv

Leitura:

Nao houve correlacao significativa forte ($p < 0.05$) entre |erro| e uma variavel isolada.
Os menores p-valores foram para macroporosity e macro_squared (~0.061), sugerindo tendencia fraca/borderline.

6.4 Erro por quadrante

Tabela:

outputs_explainability/diagnostics/error_by_quadrant.csv

Resultados:

SW: R2_log=0.583, MAE_log=0.250
NW: R2_log=0.499, MAE_log=0.272
SE: R2_log=0.549, MAE_log=0.297
NE: R2_log=0.667, MAE_log=0.276

Leitura:

O desempenho varia por regiao, indicando heterogeneidade espacial da dificuldade de predicao.

7. Consistencia fisica do modelo

Arquivos:

outputs_explainability/diagnostics/physical_consistency_checks.csv
outputs_explainability/diagnostics/physical_consistency_curves.png

Resultado dos testes de monotonia (Spearman):

macroporosity: consistente (esperado positivo, observado +0.965)
bulk_density: consistente (esperado negativo, observado -0.585)
sand: consistente (esperado positivo, observado +0.993)
clay: inconsistente (esperado negativo, observado +0.744)

Interpretacao:

O sinal invertido de clay e um alerta importante.
Possiveis causas:
- colinearidade/interacao com variaveis derivadas;
- amostragem pequena com regimes locais especificos;
- comportamento regional da BHSE diferente do padrao simplificado esperado.

8. Sintese tecnica

8.1 O que foi confirmado

O modelo aprende forte estrutura nao linear baseada em macroporosidade e interacoes.
O bloco de variaveis de macroestrutura domina explicabilidade global e local.
Ha coerencia entre SHAP e permutation para as variaveis principais.

8.2 O que exige cautela

Desempenho robusto (SLOO) cai em relacao ao holdout.
Residuos apresentam estrutura espacial remanescente (GDE ~61%).
Relacao com clay saiu fisicamente inconsistente na checagem monotonica.

8.3 Implicacao pratica

Antes de consolidar conclusoes cientificas fortes, recomenda-se:

1. testar modelagem hibrida ML + krigagem de residuos;
2. revisar conjunto de features para reduzir redundancia/colinearidade;
3. repetir checagem de consistencia fisica apos simplificacao de features;
4. manter validacao espacial como metrica principal de generalizacao.

9. Evidencias visuais principais (figuras-chave)

Global:

SHAP Beeswarm

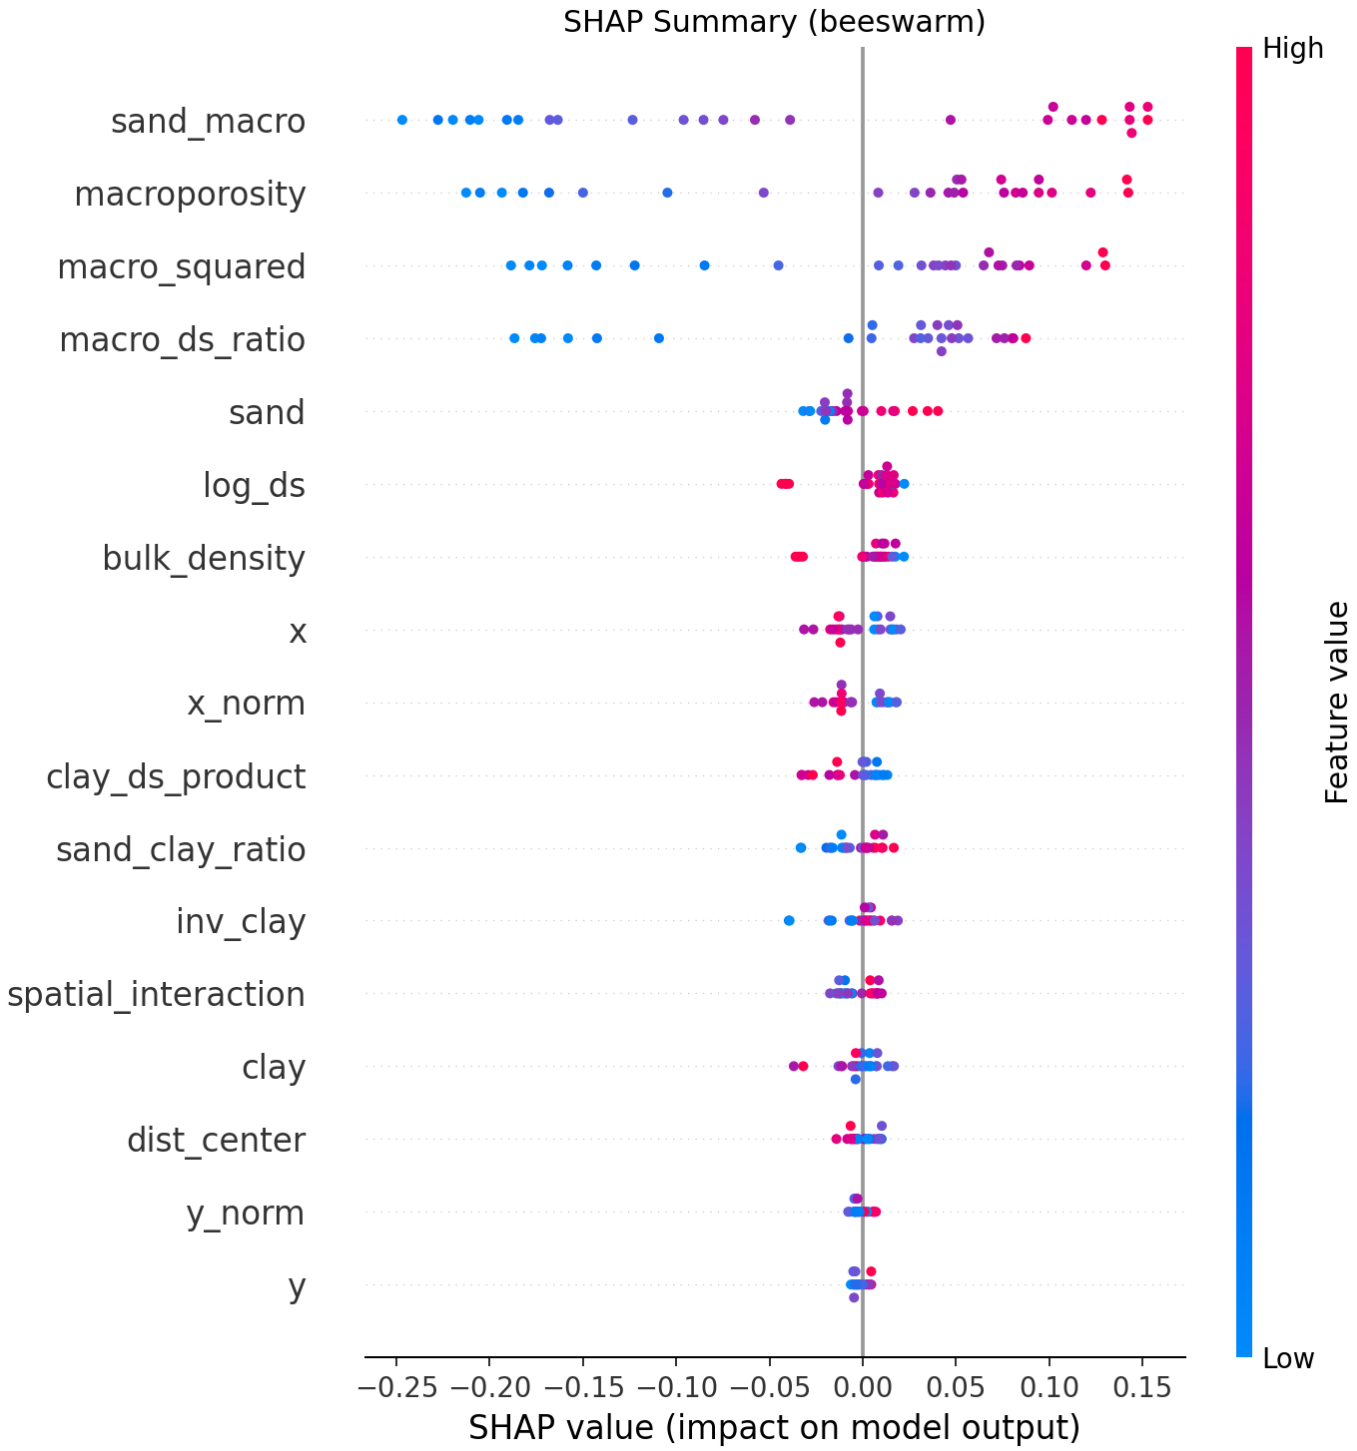

Permutation Importance

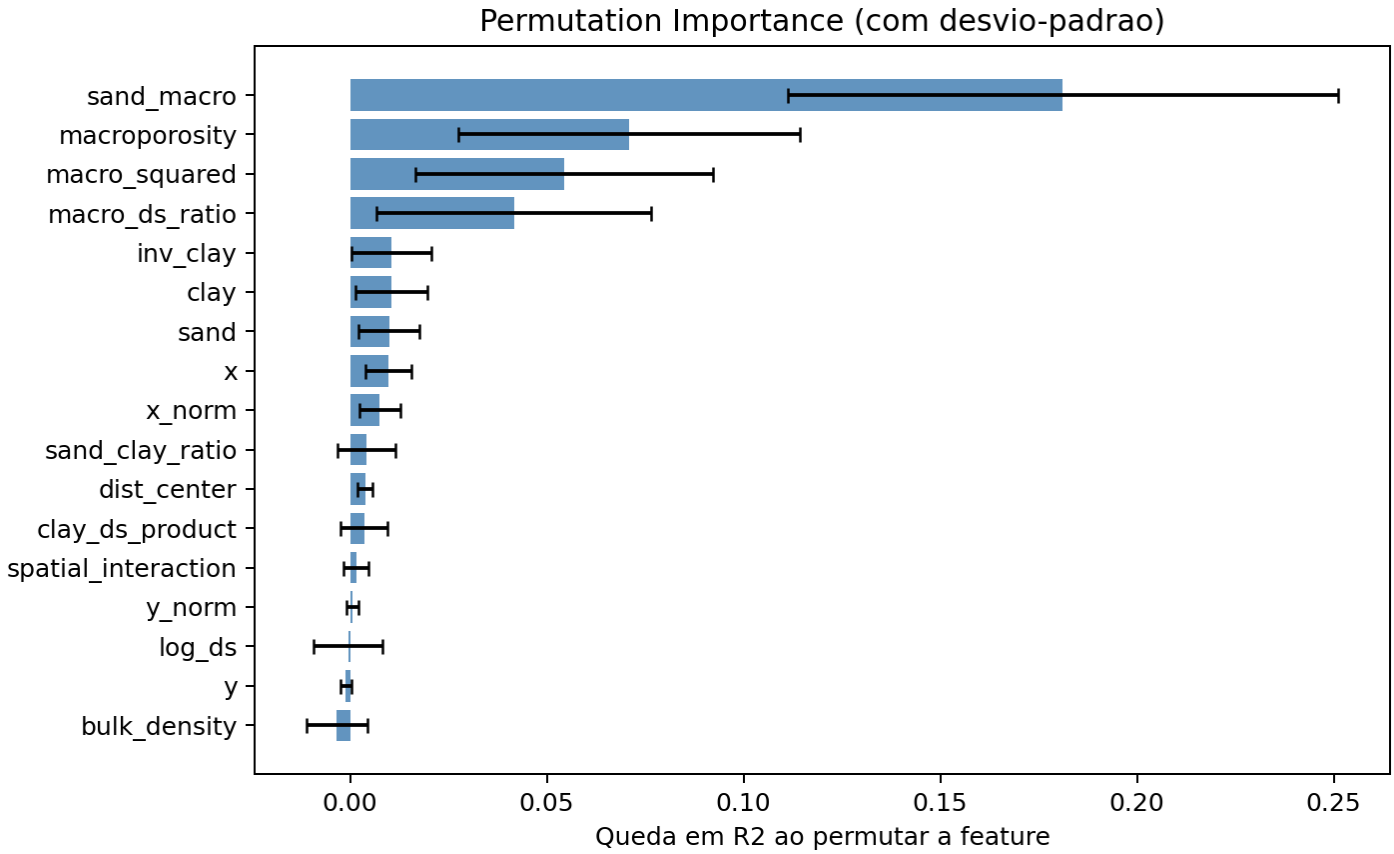

PDP + ICE

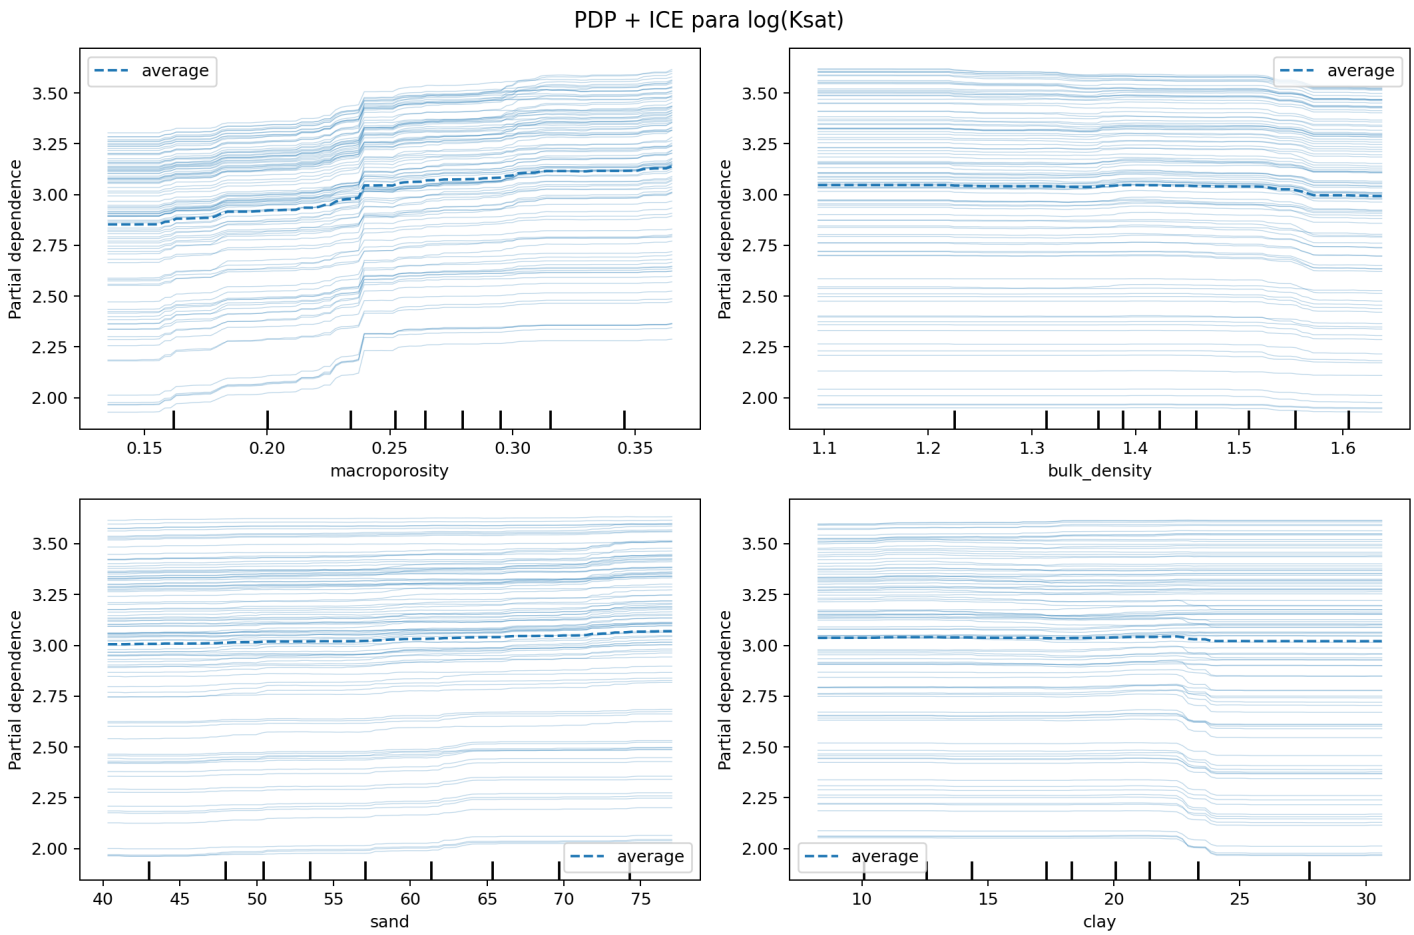

Local:

Waterfall - Pior Predicao

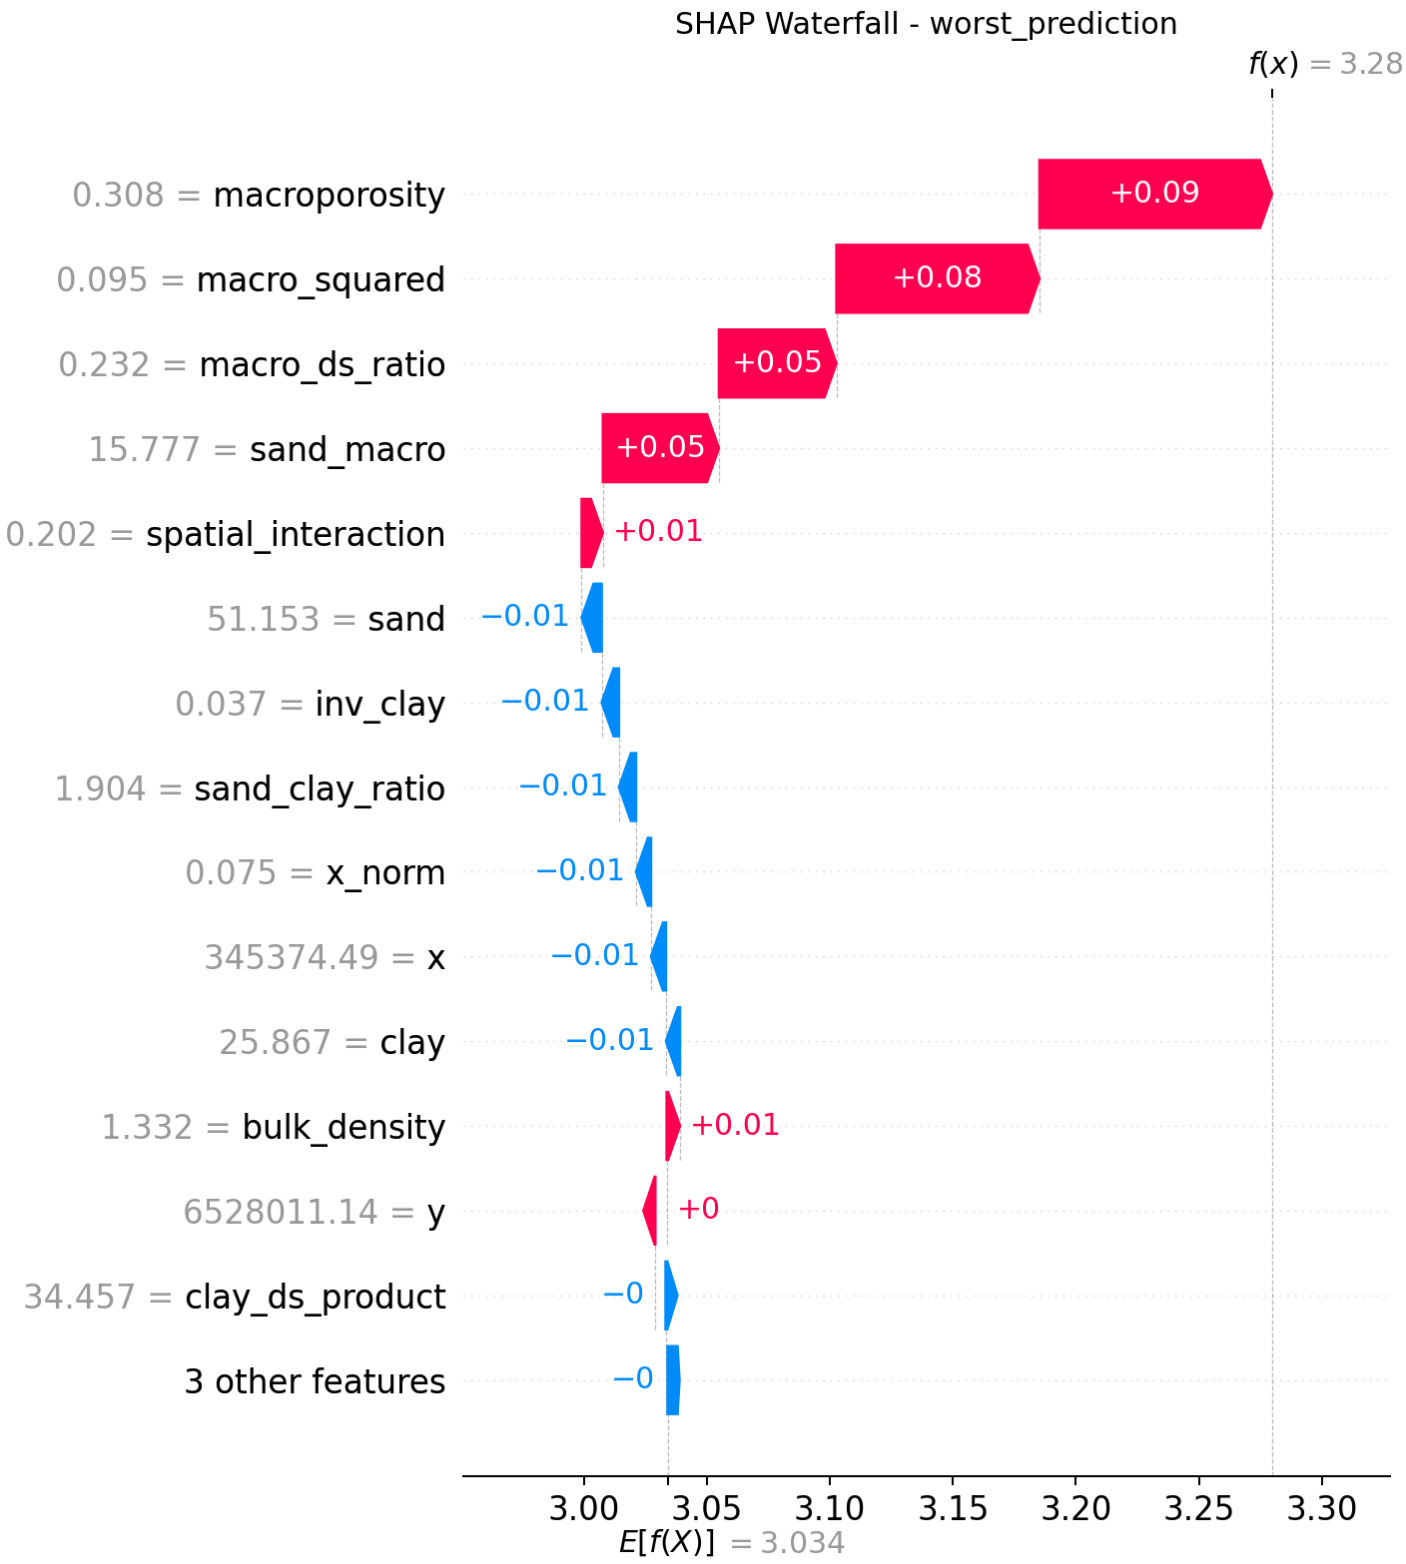

LIME - Pior Predicao

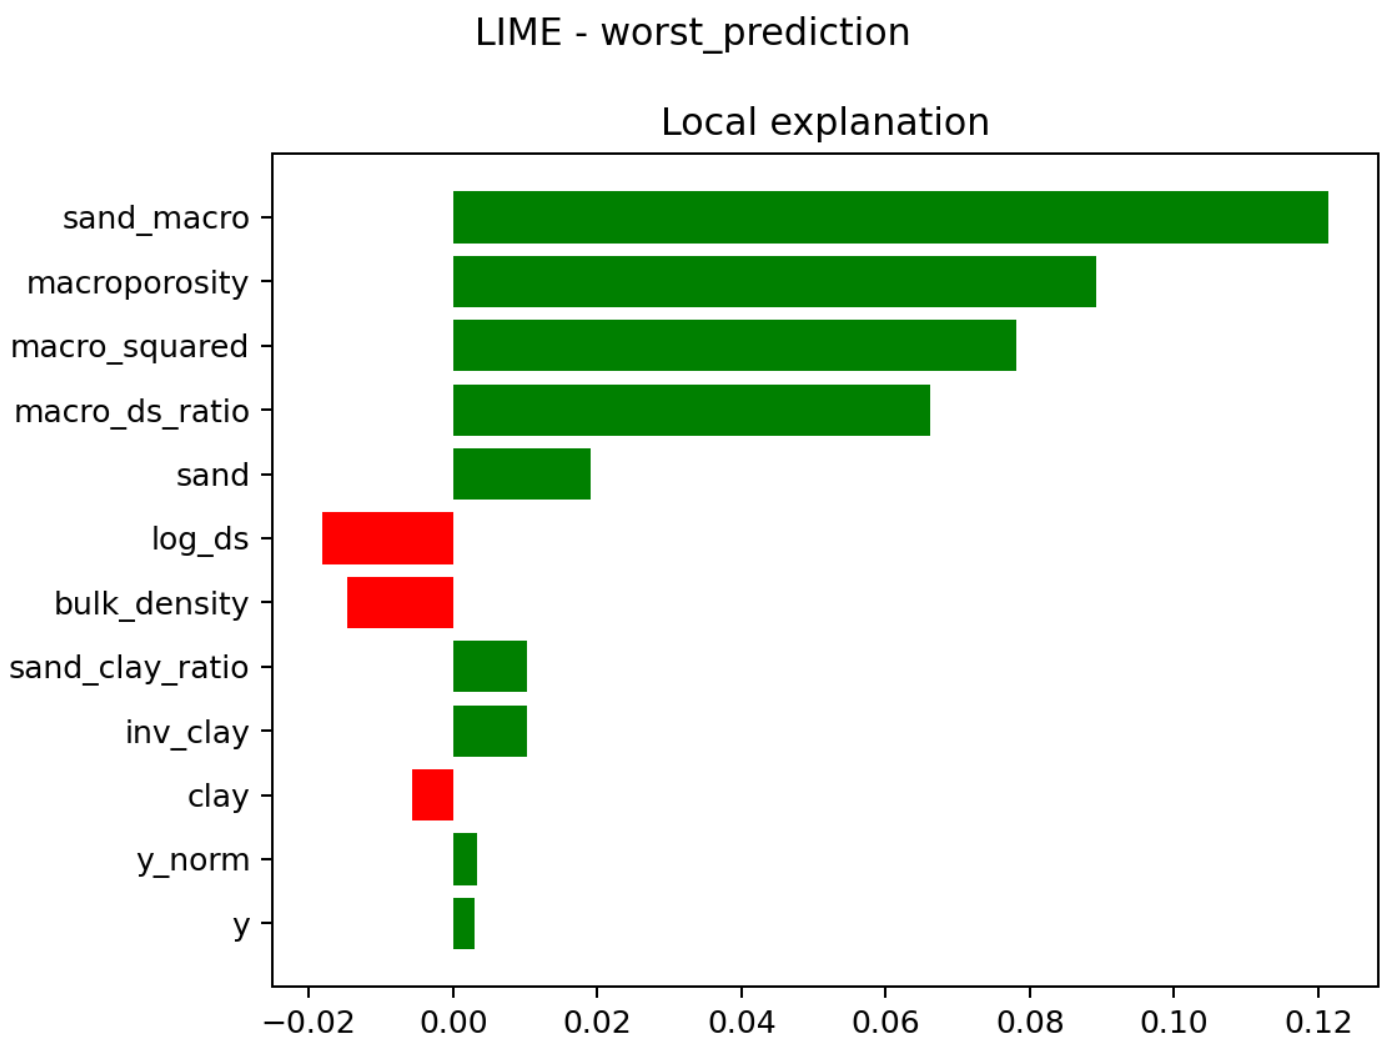

Espacial:

Mapas de Residuos (SLOO)

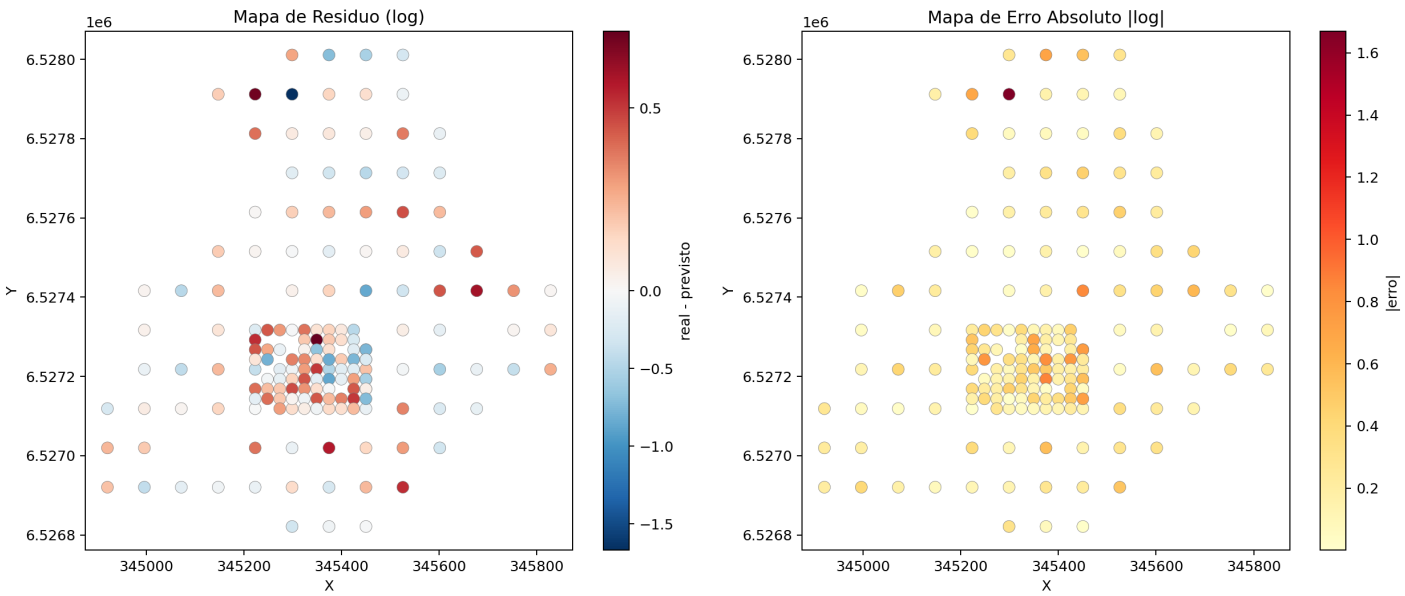

Variograma dos Residuos

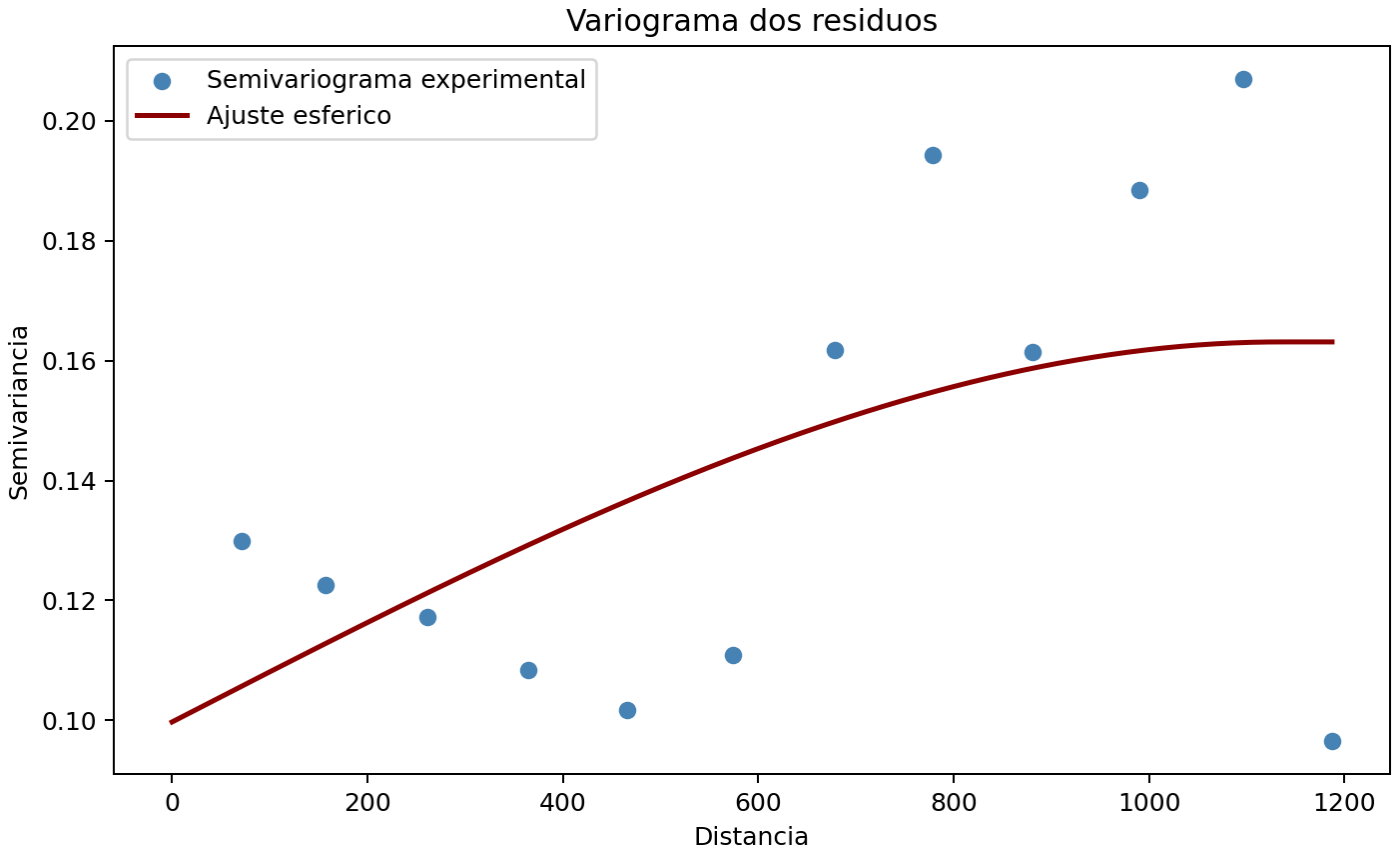

Diagnostico fisico:

Consistencia Fisica

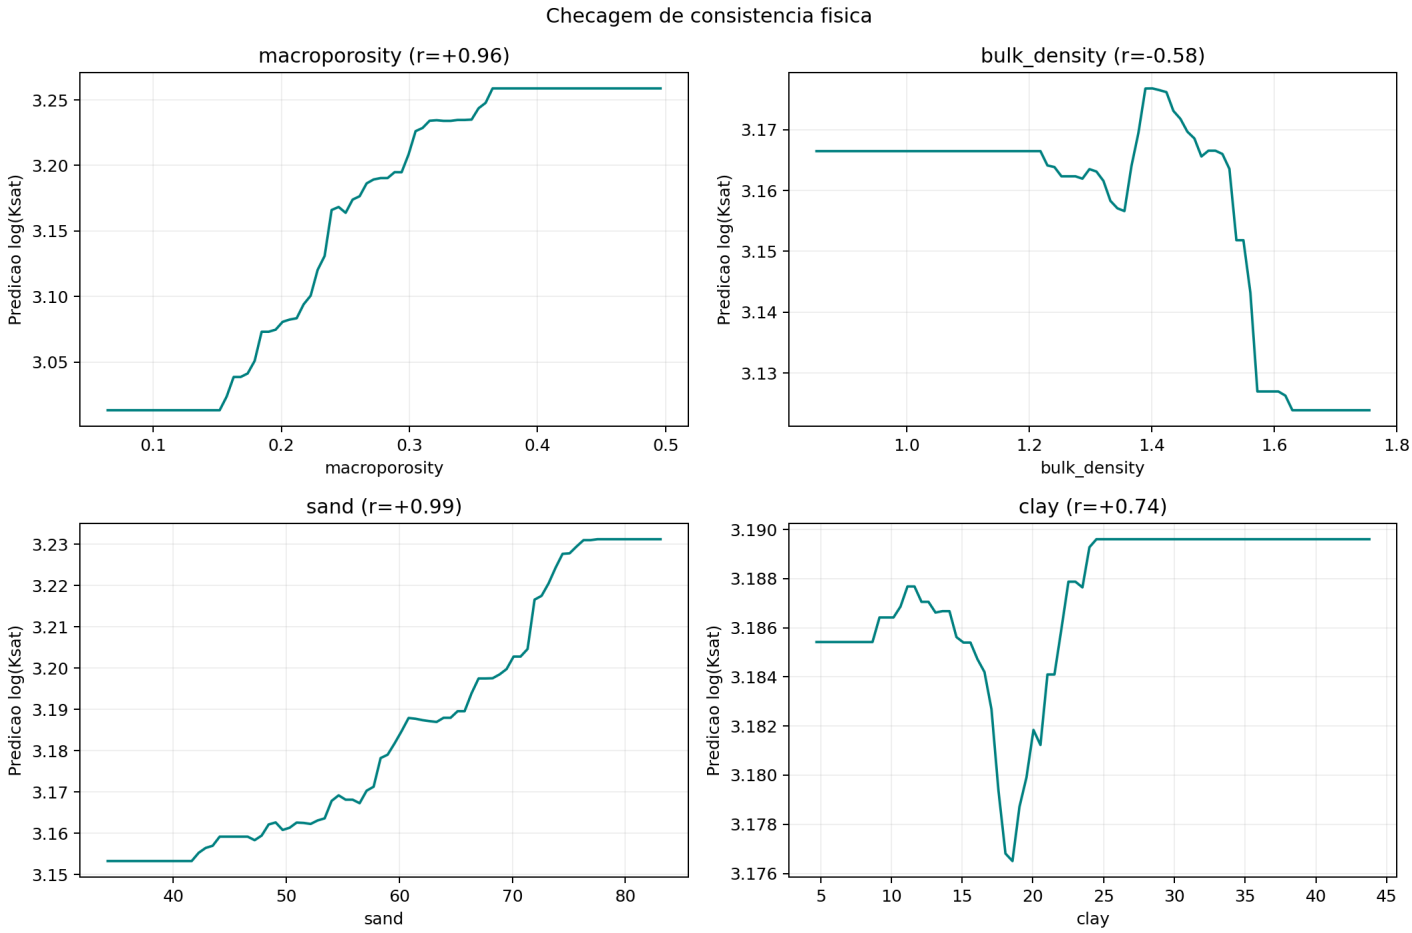

10. Reprodutibilidade

Comando executado:

```
.venv/bin/python explainability_ksat.py --model rf --feature-set engineered --sloo-max-points 169
```

Relatorio consolidado em:

RelatorioExplicabilidadeKsat.md
RelatorioExplicabilidadeKsat.pdf